



СберИндекс 2026, Кластеризация

Типы местных экономик России. Метод SPECTRA

кластеризация муниципалитетов по тратам
жителей и устройству местной экономики



Постановка задачи




**делим муниципалитеты России на типы местных экономик
и следим, как типы меняются во времени**

есть траты жителей по 6 категориям от СберИндекса,
занятость, зарплаты и население от Росстата
по 2190 МО за январь 2023 - декабрь 2024

**нужно построить сеть МО с атрибутами, найти в ней кластеры,
проследить их во времени и объяснить, что это за экономики**

качество кластеров оценивается шестью индексами (SW, CH, S_Dbw, AVI, AVU и MQ)





Ключевые результаты метода

устойчивые типы местных экономик и их изменения за год

6

типов местных экономик нашёл метод SPECTRA в сети из 1867 муниципальных образований (МО)

6 из 6

индексов качества, по которым SPECTRA не в худшей трети из 83 вариантов методов

0.53

точность (ARI) SPECTRA на синтетических данных в самом трудном для неё случае, у k-means 0.43


35

МО надёжно сменили тип за 2024 год, смена повторяется в половине и более перерасчётов

типы подтверждаются данными, которых метод не видел, все 65 крупных городов из «Четырёх Росий» Н. Зубаревич попали в тип «Города», а индекс покупательской мобильности СберИндекса сильно различается между типами ($p = 6e-18$)



Особенности данных и как они учтены



доли трат сильно зависят от сезона,
и у каждого МО сезонность своя



**считаем признаки за 12 месяцев подряд
со сдвигом на квартал,
это 5 периодов от 2023 года до 2024 года**

данные Росстата идут нарастающим итогом
с начала года и обнуляются в январе



**пересчитываем их точной формулой
в суммы за те же 12 месяцев**

районы Москвы и Петербурга это части одного
города, жители живут в одном районе,
а тратят деньги в другом



**объединяем в один МО
районы каждого из этих городов**

доли трат в сумме дают единицу, поэтому рост
одной доли сам уменьшает остальные



**используем центрированные логарифмы
отношений долей (Aitchison 1986)**

цены в регионах разные,
и одна и та же сумма значит разное



**приводим траты и зарплату
к ценам региона по стоимости
фиксированного набора товаров и услуг**





Как устроена сеть

узел сети

муниципальное образование (МО) в одном из 5 периодов, в каждом периоде 1789-1834 МО с тратами за все 12 месяцев, всего 1867 МО

ребро

соединяет МО с 10 МО, у которых самая похожая структура трат (косинусное сходство), вес ребра равен этому сходству

потребление, 7 признаков

показывает, как живут жители сюда входят доли трат на еду, маркетплейсы, транспорт, здоровье, общепит и прочее и уровень трат

труд, 11 признаков

показывает, чем МО зарабатывает
сюда входят доли работников в 9 отраслях, зарплата и число работников организаций на жителя

место, 7 признаков


описывает размер, демографию и положение МО
сюда входят население, доля горожан, плотность, доли молодых и пожилых, миграция и доступность рынков

у каждого узла 25 признаков, три блока входят с равным весом, и каждый нужен, без любого из них типы заметно меняются (ARI с итоговыми типами 0.49-0.66)



Сеть трат в 2024 году

точка это МО, цвет это его тип, ребро ведёт к МО с похожей структурой трат





- Города и агломерации
- Промышленные малые города
- Стареющая периферия
- Молодые сельские районы
- Удалённые высокозарплатные
- Юг и Северный Кавказ

1808 МО,
11 931 ребро,
одна компонента

кластеризация **0.36** против **0.007** у
случайного графа с теми же степенями

77% веса рёбер внутри типов





Рёбра по тратам, а не по географии

сравнены 11 способов провести рёбра на данных 2024 года

совпадение сообществ с регионами (NMI, 1 значит полное совпадение)



графы по географии почти повторяют деление на регионы (NMI 0.71-0.78), то есть находят регионы, а не типы экономик


порог по сходству оставляет **267** МО без единого ребра

в выбранном графе kNN по тратам внутри одного региона лежат только **14%** рёбер, а типичное ребро длиной около **1000 км**

поэтому сообщества на нём это типы экономик, разбросанные по всей стране




Рёбра по динамике трат



лаговая корреляция и DTW из условия задачи на месячных тратах за год

Moran's I признаков труда и места, которых нет в рёбрах, выше значит, что соседи по сети похожи экономикой

совпадение рёбер соседних периодов (Jaccard, 1 значит те же рёбра), среднее по 4 парам



у **61%** рёбер лаговая корреляция берёт наибольший сдвиг 3 месяца, у **12%** нулевой, это подгонка под шум

месячные траты за год после снятия общей сезонности в основном шум, поэтому время учитывается периодами и многослойной сетью, а рёбра строятся по структуре трат



Что сеть трат знает о МО

Moran's I признака на графе трат, 0 значит, что соседи не похожи



размер, плотность и доходы на сети видны,
соседи похожи (**0.60-0.70**)

отрасли почти не видны,
медиана блока «Труд» **0.30**

признаки трат не показаны,
сеть построена по ним




блок «Труд» в атрибутах добавляет
то, чего нет в графе



Метод SPECTRA

SPECTral Typology with Refinement for Attributed networks, собственная двухэтапная схема



этап 1 учитывает связи МО и их признаки сразу, вес графа α задаётся явно, разбиение устойчиво к составу МО (0.90 на 50 подвыборках)

этап 2 один раз переносит пограничные МО в более подходящий тип по критерию KEFRiN, SW 0.114 -> 0.125, S_Dbw 0.725 -> 0.704

схема, её параметры и сглаживание во времени собраны и проверены самостоятельно, этапы опираются на статьи, код написан по статьям



Как работает шаг уточнения



x_i признаки МО i , p_i его строка в стандартизованном графе трат
 c_k и λ_k центры типа k в этих пространствах, T_x и T_p их полный разброс

$$\text{cost}(i, k) = (1 - w) \cdot \|x_i - c_k\|^2 / T_x + w \cdot \|p_i - \lambda_k\|^2 / T_p$$

каждый МО один раз переходит в тип с наименьшей стоимостью

почему один шаг

итерации уводят разные подвыборки МО в разные локальные оптимумы, и устойчивость падает, а один шаг сохраняет устойчивость спектрального старта


двухэтапная схема «хороший старт и локальное уточнение» с гарантиями,
Gao et al. 2017, Lu, Zhou 2016

вес графа w	худших третей	MQ	S_Dbw
0.0	1	0.48	0.696
0.3	0	0.49	0.698
0.5	0	0.51	0.697
0.6	0	0.52	0.700
0.7	0	0.53	0.704
0.8	0	0.56	0.711
0.9	1	0.58	0.720
1.0	2	0.63	0.749

с ростом w растёт MQ,
но S_Dbw подходит к порогу худшей трети 0.711,
 $w = 0.7$ выбран с запасом


худшая треть это треть вариантов методов с худшими значениями индекса, подробнее на слайде 13





Качество в признаках и на графе

данные 2024 года, 6 типов, у каждого метода лучший вариант




- только признаки
- только граф
- признаки и граф
- **SPECTRA**

методы по признакам сильны в признаках и слабы на графе, методы по графу наоборот

SPECTRA лучше k-means по **SW, AVI, AVU и MQ**, по S_DbW почти равна (0.704 и 0.703), по CH уступает



Сравнение по индексам качества




оценивается разбиение шестью индексами, SW, CH и S_Dbw смотрят на признаки, AVI, AVU и MQ на граф
проведено сравнение 83 вариантов, это 13 методов, совместные при 11 значениях веса графа α
по каждому индексу варианты делятся на лучшую, среднюю и худшую треть,
выше стоит вариант с меньшим числом худших третей (пороговое правило Алескерова)

метод	SW	CH	S_Dbw	AVI	AVU	MQ	место из 83	устойчивость
SPECTRA	0.125	246	0.704	0.72	0.104	0.53	1	0.90
KEFRiN, евклид, α 0.6	0.113	267	0.705	0.66	0.105	0.47	1	0.82
DMoN, α 0.4	0.082	225	0.679	0.74	0.113	0.57	11	0.59
без уточнения, α 0.3	0.114	221	0.725	0.75	0.106	0.57	16	0.91
k-means	0.115	269	0.703	0.61	0.104	0.43	31	0.91

лучшая треть средняя худшая устойчивость это средний ARI разбиения 90% МО с разбиением всех МО на 50 подвыборках

без худших третей 13 вариантов, 9 из них это SPECTRA при разных α , у KEFRiN и DMoN устойчивость 0.82 и 0.59





Проверка на синтетических данных

насколько точно методы находят заранее известные типы

1

строятся синтетические МО из реальных так, чтобы размеры, центры и разброс типов были как в 2024 году,

тогда правильные типы известны

2

правильные типы берутся по очереди из трёх разных методов, SPECTRA, k-means и спектральной кластеризации по графу, чтобы проверка не давала преимущества SPECTRA

3

каждый метод лучше всех находит собственные типы, поэтому для каждого метода берётся худший из трёх результатов

точность ARI в худшем из трёх случаев, 1 значит полное совпадение




даже в худшем для себя случае SPECTRA точнее остальных методов




Шесть типов местных экономик

2024 год, тёмно-серым показаны МО без полных данных



- Города и агломерации**
321 МО, 71% населения
- Промышленные малые города**
377 МО, 10% населения
- Стареющая периферия**
657 МО, 8% населения
- Молодые сельские районы**
234 МО, 5% населения
- Удалённые высокозарплатные**
158 МО, 3% населения
- Юг и Северный Кавказ**
61 МО, 3% населения



Чем типы отличаются

Города и агломерации

321 МО, 82 млн жителей

траты 1.33, зарплата 1.24

еда 38% трат, общепит 5%, приток мигрантов

Промышленные малые города и районы

377 МО, 12.0 млн жителей

траты 1.02, зарплата 1.02

обработка 15% занятых, 71% горожан

Стареющая сельская периферия

657 МО, 9.5 млн жителей

траты 0.85, зарплата 0.82

30% старше трудоспособного возраста, бюджетный сектор 55%, отток

Молодые сельские районы

234 МО, 5.4 млн жителей

траты 0.91, зарплата 0.95

горожан нет, 21% моложе трудоспособного возраста

Удалённые территории с высокими зарплатами

158 МО, 3.6 млн жителей

траты 1.17, зарплата 1.57

0.35 работника на жителя, добыча и стройка, низкая доступность рынков

Юг и Северный Кавказ

61 МО, 3.3 млн жителей

траты 0.90, зарплата 0.76

0.10 работника организаций на жителя, бюджетный сектор 60%

Что изменилось в тратах за год


медиана изменения по МО каждого типа, 2024 год против 2023 года

тип	еда	маркетплейсы	транспорт	здоровье	общепит	прочее	уровень трат	зарплата
Города и агломерации	-1.5	+3.3	-0.1	-0.1	+0.2	-1.8	+1.8%	-0.2%
Промышленные малые города	-1.9	+4.1	-0.4	-0.2	+0.0	-1.7	-0.6%	+0.5%
Стареющая периферия	-2.1	+4.9	-0.5	-0.3	-0.1	-2.0	-1.2%	-0.8%
Молодые сельские районы	-1.7	+4.7	-0.4	-0.3	+0.0	-2.2	-1.2%	-0.2%
Удалённые высокозарплатные	-1.6	+4.0	-0.3	-0.2	+0.1	-2.2	-1.9%	-1.2%
Юг и Северный Кавказ	-1.8	+4.7	-0.3	-0.5	+0.1	-2.1	+2.6%	-0.8%

сильнее всего выросла доля **маркетплейсов**, на 3.3-4.9 п.п. в каждом типе, доли еды и прочих трат снизились на 1.5-2.2 п.п., остальные почти не изменились

уровень трат вырос только в городах (+1.8%) и на Кавказе (+2.6%), в остальных типах снизился, то есть разрыв по уровню трат растёт

поэтому дальше смотрим, как доля маркетплейсов различается между типами



Маркетплейсы по типам

периферия впереди городов, удалённые территории догоняют

доля маркетплейсов в тратах типа, если у городов она равна 1



на стареющей периферии и Кавказе
доля маркетплейсов выше, чем в
городах, и за год разрыв не
сократился


быстрее всех догоняют удалённые
территории, с **0.63** до **0.78** уровня
городов, их траты на маркетплейсах в
рублях выросли в **1.91** раза

молодые сельские районы за год
обогнали города



Где траты не следуют за экономикой

уровень трат предсказан по 18 признакам труда и места, out-of-fold R^2 0.78



тратят больше прогноза


- +45% Тоцкий, Оренбургская обл.
- +43% Благовещенский, Амурская обл.
- +41% Заокский, Тульская обл.
- +41% Камышловский, Свердловская обл.
- +40% Псковский, Псковская обл.

тратят меньше прогноза

- 33% Большеулуйский, Красноярский кр.
- 32% Красноярский, Астраханская обл.
- 32% Мезенский, Архангельская обл.
- 31% Светловский, Калининградская обл.
- 28% Городищенский, Волгоградская обл.


■ ниже на 15%+ ■ ниже на 5-15% ■ в пределах 5% ■ выше на 5-15% ■ выше на 15%+

больше тратят пригороды, курорты и гарнизоны, меньше районы добычи и вахты



Как связаны периоды между собой

многослойная сеть, Mucha et al. 2010



А это блочная матрица, на диагонали стоят сети пяти периодов $W_1, \dots, W_5$

каждый МО связан со своей копией в соседнем периоде ребром веса c / N , $c = 1$, это та же сила, что у всех его связей внутри периода

спектральная кластеризация А даёт типы **сразу во всех периодах**, и номер типа сохраняет смысл без сопоставления

шаг уточнения со сглаживанием

$$D_t(i, k) = \sum_u 0.3^{|t-u|} \cdot d_u(i, k) / \sum_u 0.3^{|t-u|}$$

d_u это стоимость типа в периоде u , тип МО в периоде t это argmin по k

пограничные МО не прыгают между типами туда и обратно



Пять способов связать периоды

доля МО, сменивших тип между 2023 и 2024 годом



соседние периоды делят 9 месяцев из 12, а независимая кластеризация меняет тип у **половины** МО

фиксированная типология и сильная память гасят изменения ценой качества

многослойная сеть сохраняет качество периодов и меняет тип только у **7%** МО



Смены типа за 2024 год

7.1%

МО сменили тип, 126 из 1776

35

смен надёжны, они повторяются не меньше чем в половине из 300 перерасчётов

31% и 0.4%

МО сменили тип при уверенности ниже 0.7 и от 0.9, то есть смены идут на границах типов

самые частые смены типа

● стареющая периферия	→	● промышленные	25
● молодые сельские	→	● стареющая периферия	23
● молодые сельские	→	● промышленные	11
● промышленные	→	● города	10

куда ведут надёжные смены

в города переходят МО ближе к столицам регионов, медиана **60 км** против 107 км у всех МО

если строить типы по каждому месяцу, их меняют 22% МО в месяц, и 44% таких смен откатываются за два месяца, это сезонность

Как проверены результаты



$p = 6e-18$

индекс покупательской
мобильности СберИндекса,
которого не было в модели,
различается между типами

5 из 5

показателей Росстата, которых не
было в модели, различаются
между типами, для четырёх $p < 1e-57$

65 из 65

крупных городов «Четырёх
Россий» Н. Зубаревич попали в
тип «Города»

0.94

медианная уверенность типа на
300 перерасчётах SPECTRA по
случайным 90% МО


AUC 0.91

уверенность отделяет МО,
сменившие тип, смены идут на
границах типов

26 тестов

метрики сверены с networkx и
первоисточниками, совместные
методы написаны нами по
статьям





Как использовать результаты

готовая типология

тип каждого МО в каждом периоде, уверенность и надёжные смены типа лежат в папке results

сравнение и контрольные группы

МО одного типа это похожие экономики, с ними сравнивают и из них выбирают контрольные группы

мониторинг

надёжная смена типа это повод разобраться, что произошло с МО

ограничения

траты только за 2023-2024 годы, Росстат без малого бизнеса, индекс мобильности только для Северо-Запада, пограничные МО лучше считать смешанными

обновление при выходе новых данных

```
python run.py features
```

```
python run.py track
```

параметры SPECTRA в config.yaml

код, данные и атлас

github.com/YuliaVyaznikova/sberindex-clustering

yuliavyaznikova.github.io/sberindex-clustering